# **SPRAWOZDANIE**

Zajęcia: Eksploracja i wizualizacja danych Prowadzący: prof. dr hab. Vasyl Martsenyuk

# Laboratorium 1

30.10.2021

Temat: "Wstęp do Python. Biblioteka Pandas"

Marek Bubiak Informatyka II stopień, niestacjonarne (zaoczne), III semestr, https://github.com/JeremyCoco/eiwd 1. Ładowanie biblioteki Pandas

```
In [1]: # tadowanie biblioteki Pandas
import pandas as pd
```

2. Tworzenie ramki danych ze słownika

```
In [2]: # tworzenie ramki danych ze słownika

dane = {
    "Numer" : [1,2,3,4,5,6,7],
    "Dzien" : ["Poniedziałek","Wtorek","Środa","Czwartek","Piątek","Sobota","Niedziela"]
}

df = pd.DataFrame(dane)
df
```

Out[2]:

Dzie	umer	N
Poniedziałe	1	0
Wtore	2	1
Środ	3	2
Czwarte	4	3
Piąte	5	4
Sobot	6	5
Niedzie	7	6

3. Zachowanie ramki danych pobranych z pliku w formacie csv (xlsx)

```
In [4]: # zachowanie ramki danych na komputerze w formacie csv
path = r"C:\Users\Dzikus\Downloads\daneZeSlownika.csv"
df.to_csv(path, encoding="utf-8")
```

4. Tworzenie ramki danych z listy list

```
In [5]: # tworzenie ramki danych z listy list
    week_days = [
            [1,2,3,4,5,6,7],
            ["Poniedziałek","Wtorek","Środa","Czwartek","Piątek","Sobota","Niedziela"]
            ]
            pd.DataFrame(week_days)
```

Out[5]:

	0	1	2	3	4	5	6
0	1	2	3	4	5	6	7

- 1 Poniedziałek Wtorek Środa Czwartek Piątek Sobota Niedziela
- 5. Transponowanie (wymieniamy kolumny a wierszy)

```
In [6]: # transponowanie (wymieniamy kolumny a wierszy)
         pd.DataFrame(week_days).T
Out[6]:
            0
          0 1 Poniedziałek
          1 2
                   Wtorek
                    Środa
          2 3
          3 4
                  Czwartek
          4 5
                    Piątek
          5 6
                   Sobota
                  Niedziela
          6 7
```

## 6. Wyświetlić pierwsze 10 wierszy ramki danych

```
In [15]: #wczytanie danych z pliku *.csv
path = r"C:\Users\Dzikus\Downloads\IHME_GDP_1960_2050_CSV_1\IHME_GDP_1960_2050_Y2021M09D22.CSV"

df = pd.read_csv(path, low_memory=False, )

# pierwsze 10 wierszy ramki danych
df.head(10)
```

Out[15]:

	location_id	location_name	iso3	level	year	gdp_ppp_mean	gdp_ppp_lower	gdp_ppp_upper	gdp_usd_mean	gdp_usd_lower	gdp_usd_upper
0	1	Global	G	Global	1960	1.748345e+13	1.601915e+13	1.911586e+13	1.296863e+13	1.266890e+13	1.334177e+13
1	1	Global	G	Global	1961	1.813537e+13	1.659537e+13	1.982493e+13	1.346097e+13	1.314767e+13	1.383021e+13
2	1	Global	G	Global	1962	1.895328e+13	1.739039e+13	2.061477e+13	1.406576e+13	1.376060e+13	1.443746e+13
3	1	Global	G	Global	1963	1.965662e+13	1.811706e+13	2.134993e+13	1.461831e+13	1.432132e+13	1.497693e+13
4	1	Global	G	Global	1964	2.100575e+13	1.935664e+13	2.276791e+13	1.552986e+13	1.523498e+13	1.587998e+13
5	1	Global	G	Global	1965	2.202459e+13	2.034585e+13	2.382275e+13	1.628972e+13	1.598727e+13	1.663310e+13
6	1	Global	G	Global	1966	2.306193e+13	2.136085e+13	2.489782e+13	1.708885e+13	1.678223e+13	1.742396e+13
7	1	Global	G	Global	1967	2.391268e+13	2.217842e+13	2.577837e+13	1.770884e+13	1.740660e+13	1.804193e+13
8	1	Global	G	Global	1968	2.516723e+13	2.340479e+13	2.698215e+13	1.865379e+13	1.8332 <mark>1</mark> 6e+13	1.898399e+13
9	1	Global	G	Global	1969	2.642403e+13	2.464521e+13	2.831984e+13	1.955395e+13	1.921164e+13	1.987990e+13

### 7. Wyświetlić ostatnie 10 wierszy ramki danych

In [16]: # ostatnie 10 wierszy ramki danych df.tail(10)

Out[16]:

	location_id	location_name	iso3	level	year	gdp_ppp_mean	gdp_ppp_lower	gdp_ppp_upper	gdp_usd_mean	gdp_usd_lower	gdp_usd_upper
19828	44578	Low income	NaN	World Bank Income Group	2041	3.120963e+12	2.724077e+12	3.582807e+12	9.752426e+11	8.875033e+11	1.068693e+12
19829	44578	Low income	NaN	World Bank Income Group	2042	3.216988e+12	2.801335e+12	3.686394e+12	1.008813e+12	9.169149e+11	1.107239e+12
19830	44578	Low income	NaN	World Bank Income Group	2043	3.314031e+12	2.886768e+12	3.815672e+12	1.042881e+12	9.461940e+11	1.147550e+12
19831	44578	Low income	NaN	World Bank Income Group	2044	3.413020e+12	2.968361e+12	3.933135e+12	1.077714e+12	9.735487e+11	1.188093e+12
19832	44578	Low income	NaN	World Bank Income Group	2045	3.514244e+12	3.055623e+12	4.049325e+12	1.113207e+12	1.003241e+12	1.228145e+12
19833	44578	Low income	NaN	World Bank Income Group	2046	3.617310e+12	3.140835e+12	4.166469e+12	1.149318e+12	1.031500e+12	1.271992e+12
19834	44578	Low income	NaN	World Bank Income Group	2047	3.724063e+12	3.225849e+12	4.292403e+12	1.186597e+12	1.061313e+12	1.318836e+12
19835	44578	Low income	NaN	World Bank Income Group	2048	3.831942e+12	3.307609e+12	4.424674e+12	1.224062e+12	1.092874e+12	1.365610e+12
19836	44578	Low income	NaN	World Bank Income Group	2049	3.941856e+12	3.398884e+12	4.560961e+12	1.262129e+12	1.122895e+12	1.413991e+12
19837	44578	Low income	NaN	World Bank Income Group	2050	4.053883e+12	3.482933e+12	4.713596e+12	1.300764e+12	1.151548e+12	1.457362e+12

### 8. Wyświetlić informację o ramce danych

```
In [18]: # informacja o ramce danych
            df.info()
             <class 'pandas.core.frame.DataFrame'>
            RangeIndex: 19838 entries, 0 to 19837
            Data columns (total 11 columns):
                                     Non-Null Count Dtype
              # Column
             0 location_id 19838 non-null int64
                   location_name 19838 non-null object
                  iso3
                                      18655 non-null object
                   level
                                       19838 non-null object
                                       19838 non-null int64
                  year
                 gdp_ppp_mean 19838 non-null float64
gdp_ppp_lower 19838 non-null float64
             7 gdp_ppp_upper 19838 non-null float64
8 gdp_usd_mean 19838 non-null float64
            gup_usu_mean 19838 non-null float64

9 gdp_usd_lower 19838 non-null float64

10 gdp_usd_upper 19838 non-null float64

dtypes: float64(6), int64(2), object(3)

memory usage: 1.7+ MB
```


9. Wyświetlić, ile wierszy i kolumn znajduje się w ramce danych

```
In [19]: # pokazuje, ile wierszy i kolumn znajduje się w ramce danych
df.shape
Out[19]: (19838, 11)
```


10. Wyświetlić informacje, statystyczna, o kolumnach liczbowych (wartości niepowtarzalne, średnia, odchylenie standardowe, minimum, kwartyle, maksimum)

```
In [20]: # informacje statystyczne w kolumnach (wartości niepowtarzalne,
           średnia, odchylenie standardowe, minimum, kwartyle, maksimum)
         df.describe()
Out[20]:
                  location id
                                   year gdp_ppp_mean gdp_ppp_lower gdp_ppp_upper gdp_usd_mean gdp_usd_lower gdp_usd_upper
          count 19838.000000 19838.000000
                                         1.983800e+04
                                                       1.983800e+04
                                                                     1.983800e+04
                                                                                   1.983800e+04
                                                                                                1.983800e+04
                                                                                                              1.983800e+04
                  949.871560 2005.000000 1.334543e+12 1.235788e+12
                                                                     1.444079e+12
                                                                                   8.554096e+11
                                                                                                8.197528e+11
                                                                                                              8.967612e+11
          mean
            std 5965.433243
                            26.268513 9.148287e+12 8.610030e+12 9.789327e+12 6.286364e+12 6.041288e+12 6.585419e+12
                   1.000000 1960.000000 1.448063e+02 6.299026e+01
                                                                     2.621094e+02
                                                                                  1.174979e+02 8.318772e+01
                                                                                                             1.270468e+02
            min
                  63.000000 1982.000000 3.678736e+03 2.639116e+03
                                                                    4.829886e+03
                                                                                  1.624411e+03 1.395430e+03 1.828575e+03
           25%
                  125.500000 2005.000000
                                         1.103640e+04 8.105541e+03
                                                                     1.346178e+04
                                                                                  4.863298e+03 4.279291e+03
                                                                                                              5.465731e+03
                  183.000000 2028.000000 2.949281e+04 2.308992e+04
                                                                    3.562660e+04 1.997525e+04 1.795003e+04 2.223434e+04
            max 44578.000000 2050.000000
                                                      1.667007e+14
                                                                                                1.017185e+14 1.239708e+14
```


11. Wyświetlić informację statystyczną o kolumnach kategoryzowanych (ile unikalnych wartości, top - jaka jest najpopularniejsza wartość, freq - jak często najpopularniejsza)




12. Usunąć brakujące wartości w ramce danych



13. Przedstawić wybór wierszy z ramki danych pod warunkiem odnośnie określonej wartości kolumny



14. Przedstawić wybór wierszy z ramki danych pod warunkiem spełnienia kilku warunków jednocześnie



15. Wybrać wiersze które zawierają w kolumnie kategoryzowanej określone słowo



16. Wybrać wiersze które nie zawierają w kolumnie kategoryzowanej określone słowo

```
selection = df[df["location_name"] != "Asia"]
        selection.head()
Out[35]:
           location_id location_name iso3 level year gdp_ppp_mean gdp_ppp_lower gdp_ppp_upper gdp_usd_mean gdp_usd_lower gdp_usd_upper
                            Global
                                    G Global 1960
                                                     1.748345e+13
                                                                   1.601915e+13
                                                                                 1.911586e+13
                                                                                                1.296863e+13
                                                                                                              1.266890e+13
                                     G Global 1961
                                                     1.813537e+13
                                                                    1.659537e+13
                                                                                                1.346097e+13
                                                                                                              1.314767e+13
                                    G Global 1962
                                                     1.895328e+13
                                                                   1.739039e+13
                                                                                  2.061477e+13
                                                                                                1.406576e+13
                                                                                                              1.376060e+13
                                                                                                                            1.443746e+13
        3
                            Global
                                     G Global 1963
                                                     1.965662e+13
                                                                                 2.134993e+13
                                                                                               1.461831e+13
                                                                                                              1.432132e+13
                                                                                                                            1.497693e+13
                                                                   1.811706e+13
                            Global G Global 1964
                                                     2.100575e+13 1.935664e+13
                                                                                 2.276791e+13 1.552986e+13 1.523498e+13 1.587998e+13
```


17. Utwórz kolumnę na podstawie istniejącej

```
In [36]:
         location name = df.location name
         location name
Out[36]: 0
                 Global
                 Global
                 Global
                 Global
                 Global
         19469
                  Sudan
         19470
                  Sudan
         19471
                  Sudan
         19472
                  Sudan
         19473
                  Sudan
         Name: location_name, Length: 18655, dtype: object
```

18. Usuń kolumnę

```
In [38]:
       df_copy = df
        df_copy.drop(["location_name", "iso3"], axis=1, inplace=True)
       df_copy.head()
Out[38]:
           location id
                       level year gdp_ppp_mean gdp_ppp_lower gdp_ppp_upper gdp_usd_mean gdp_usd_lower gdp_usd_upper
                                                                                                                1.334177e+13
        0
                   1 Global 1960
                                     1.748345e+13
                                                   1.601915e+13
                                                                   1.911586e+13
                                                                                  1.296863e+13
                                                                                                1.266890e+13
        1
                   1 Global 1961
                                     1.813537e+13
                                                   1.659537e+13
                                                                   1.982493e+13
                                                                                  1.346097e+13
                                                                                                1.314767e+13
                                                                                                                1.383021e+13
        2
                   1 Global 1962
                                     1.895328e+13
                                                   1.739039e+13
                                                                   2.061477e+13
                                                                                  1.406576e+13
                                                                                                1.376060e+13
                                                                                                                1.443746e+13
        3
                                                                                                                1.497693e+13
                   1 Global 1963
                                    1.965662e+13
                                                   1.811706e+13
                                                                   2.134993e+13
                                                                                 1.461831e+13
                                                                                                1.432132e+13
                   1 Global 1964
                                    2.100575e+13
                                                   1.935664e+13
                                                                   2.276791e+13
                                                                                  1.552986e+13
                                                                                                1.523498e+13
                                                                                                                1.587998e+13
```

19. Zmień nazwę kolumny



20. Zachowaj ramkę danych jako plik csv na komputerze

```
path = r"C:\Users\Dzikus\Downloads\df_copy.csv"
df.to_csv(path, encoding="utf-8")
```

21. Wyświetlić średnia (maksymalną, minimalną) wartość z jednej kolumny

```
In [42]: col = df["gdp_ppp_mean"]
    mean = col.mean()
    _max = col.max()
    _min = col.min()

    print(f"Średnia: {mean}\nMaksimum: {_max}\nMinimum: {_min}")

    Średnia: 448950770593.6332
    Maksimum: 182741391837932.0
    Minimum: 144.806256438462
```

22. Wyświetlić liczbę wierszy

```
In [43]: df.rok.count()
Out[43]: 18655
```

23. Wyświetlić wartości unikatowe w kolumnie

24. Wyświetlić liczby rekordów odpowiadających do wartości

```
In [50]: df_copy[df_copy["id"] == 187].rok.count()
out[50]: 91
```

25. Sortowanie wierszy ramki danych według wartości określonej kolumny (malejąco, rosnąco)

		12.0000000		1 10 0 10 20 00 00 00 00 00 00 00 00 00 00 00 00		10.00	I NOW A SPECIAL DESIGNATION OF THE PARTY OF		TANKS AND SOME TOWNS AND
ÿ <u>.</u>	id	level	rok	gdp_ppp_mean	gdp_ppp_lower	gdp_ppp_upper	gdp_usd_mean	gdp_usd_lower	gdp_usd_upper
15258	187	Country	2021	144.806256	62.990256	262.109448	117.497898	106.885540	127.046786
15259	187	Country	2022	145.845802	63.336551	264.032901	118.340834	107.636300	128.366648
15260	187	Country	2023	147.061289	63.853934	266.073159	119.326124	108.370797	129.740750
15257	187	Country	2020	151 493017	70 883163	266 749076	123.193355	112.066586	133 205105

26. Wyświetlić wierszy dla 10 największych (najmniejszych) wartości określonej kolumny

```
In [54]: df.nlargest(10, 'gdp_ppp_mean')[['rok', 'gdp_ppp_mean']]
out[54]:
            rok gdp ppp mean
                  1.827414e+14
        90 2050
                  1.811701e+14
        89 2049
        88 2048
                 1.795422e+14
        87 2047
                  1.778053e+14
        86 2046
                 1.759560e+14
        85 2045
                  1.740498e+14
        84 2044
                 1.720934e+14
        83 2043
                 1.701152e+14
        82 2042
                 1.681175e+14
        81 2041
                 1.661209e+14
```

27. Wyświetlić wierszy dla 10 największych wartości określonej kolumny pod warunkiem określonych wartości innej kolumny

	df[(df	['id	'].isin	([187	37, 192])) & (df['rok'] == 2003)]							
57]:		id	level	rok	gdp_ppp_mean	gdp_ppp_lower	gdp_ppp_upper	gdp_usd_mean	gdp_usd_lower	gdp_usd_upper		
	15240	187	Country	2003	165.077376	75.241513	281.85689	134.639462	125.515319	143.91606		

- 28. Grupowanie wierszy według wartości kolumny kategoryzowanej, potem
  - uśrednienie wartości wszystkich kolumn w grupie MultiIndex

	id	gdp_ppp_mean	gdp_ppp_lower	gdp_ppp_upper	gdp_usd_mean	gdp_usd_lower	gdp_usd_upper
rok							
1960	135.639024	8.528513e+10	7.814218e+10	9.324812e+10	6.326159e+10	6.179953e+10	6.508179e+10
1961	135.639024	8.846523e+10	8.095304e+10	9.670697e+10	6.566329e+10	6.413496e+10	6.746446e+10
1962	135.639024	9.245503e+10	8.483118e+10	1.005599e+11	6.861346e+10	6.712486e+10	7.042663e+10
1963	135.639024	9.588596e+10	8.837590e+10	1.041460e+11	7.130884e+10	6.986011e+10	7.305819e+10
1964	135.639024	1.024671e+11	9.442264e+10	1.110630e+11	7.575543e+10	7.431699e+10	7.746333e+10
		***	177			1757	55
2046	135.639024	8.583220e+11	7.915827e+11	9.409579e+11	5.275673e+11	4.862689e+11	5.759145e+11
2047	135.639024	8.673428e+11	7.978932e+11	9.526097e+11	5.326453e+11	4.893155e+11	5.842021e+11
2048	135.639024	8.758158e+11	8.034297e+11	9.650481e+11	5.373930e+11	4.920505e+11	5.915018e+11
2049	135.639024	8.837564e+11	8.086222e+11	9.772106e+11	5.418284e+11	4.939856e+11	5.981921e+11
2050	135.639024	8.914214e+11	8.131744e+11	9.878353e+11	5.460821e+11	4.961880e+11	6.047354e+11

29. Grupowanie wierszy według wartości kolumny kategoryzowanej, potem - uśrednienie wartości dla pewnych kolumn, liczba wartości i mediana dla pozostałych kolumn w grupach

```
In [70]: data = df.groupby('location_name').agg({'location_id': ['mean'], 'gdp_ppp_mean': ['mean'],
         'gdp_ppp_lower': ['mean'], 'year': ['count'], 'gdp_ppp_upper': ['median'], 'gdp_usd_mean': ['median']})
        data
out[70]:
                                           location_id gdp_ppp_mean gdp_ppp_lower year
                                                                                              gdp_ppp_upper gdp_usd_mean
                                                                                       count median
                           location_name
                              Afghanistan
                                                160.0
                                                          1941.160286
                                                                          1236.392538
                                                                                                  2776.309765
                                                                                                                   515.274036
                                  Albania
                                                 43.0
                                                          9092.515182
                                                                          7497.502508
                                                                                           91
                                                                                                  9075.499017
                                                                                                                  3098.516205
                                  Algeria
                                                139.0
                                                          8820.271149
                                                                          6354.741822
                                                                                           91
                                                                                                 11218.304481
                                                                                                                  3163.885729
                         American Samoa
                                                298.0
                                                         15340.365197
                                                                         13676.178347
                                                                                           91
                                                                                                 15350.704406
                                                                                                                 13620.772462
                                                 74.0
                                                         25139.562251
                                                                         19212.344640
                                                                                           91
                                                                                                 34824,933478
                                  Andorra
                                                                                                                 38178.372791
                                                133.0
                                                                                           91
         Venezuela (Bolivarian Republic of)
                                                         10594.142490
                                                                          6906.942146
                                                                                                 16306.155638
                                                                                                                  5823.785745
                                 Viet Nam
                                                 20.0
                                                          5737.873614
                                                                          3963.905853
                                                                                           91
                                                                                                  5395.236220
                                                                                                                  1437.919432
                                                157.0
                                   Yemen
                                                          2637.237249
                                                                          1253.872401
                                                                                                  4512.871947
                                                                                                                   828.806903
                                  Zambia
                                                191.0
                                                          3107.029470
                                                                          2256.455986
                                                                                                  4016.872139
                                                                                                                  1078.009951
                                                          2925.918096
                               Zimbabwe
                                                198.0
                                                                          2053.892011
                                                                                                  3621.537763
                                                                                                                  1069.856772
```


30. Wyświetlić nazwy kolumn indeksu złożonego

216 rows × 6 columns

31. Sortować kolumnę indeksu złożonego


```
data['gdp ppp lower']['mean'].sort values(ascending=False)
Out[73]: location_name
         Global
                                                  8.770511e+13
         High income
                                                  4.296017e+13
         High-income
                                                  3.910369e+13
         Upper-middle income
                                                  2.770854e+13
         Southeast Asia, East Asia, and Oceania
                                                  1.644275e+13
         Niger
                                                  9.053953e+02
         Mozambique
Burundi
                                                  8.709698e+02
                                                  8.240844e+02
         Malawi
                                                  7.925530e+02
         Somalia
                                                  9.249822e+01
         Name: mean, Length: 216, dtype: float64
```

32. Stworzyć tabelę przystawną (pivot table) na podstawie ramki danych



33. Wyświetlić indeksy i kolumny tabeli przystawnej

34. Utwórz indeks złożony tabeli przystawnej i wyświetl go



35. Zaimportuj moduł pyplot z biblioteki matplotlib

```
import matplotlib.pyplot as plt


%matplotlib inline
```

36. Wskazać, że wykresy należy rysować bezpośrednio w zeszycie, a nie w osobnej zakładce


```
import matplotlib.pyplot as plt

%matplotlib inline
```

37. Wyświetlić wykres na podstawie tabeli przystawnej



38. Narysować histogram na podstawie wartości kolumny



39. Pokazać dodawanie nowych kolumn za pomocą operacji matematycznych

```
In [64]: df['sum'] = df['gdp_ppp_mean'] + df['gdp_ppp_lower']
       df[['gdp_ppp_mean', 'gdp_ppp_lower', 'sum']].tail()
Out[64]:
              gdp_ppp_mean gdp_ppp_lower
                                                 sum
       19833
               3.617310e+12 3.140835e+12 6.758144e+12
               3.724063e+12
        19834
                             3.225849e+12 6.949912e+12
        19835
               3.831942e+12 3.307609e+12 7.139551e+12
        19836
               3.941856e+12 3.398884e+12 7.340739e+12
        19837
               4.053883e+12 3.482933e+12 7.536816e+12
```

40. Przedstawić na przykładzie dodawanie nowych kolumn z pomocą funkcji lambda

```
In [65]: df['years_ago'] = df['year'].apply(lambda y: 2051 - int(y))
       df[['year', 'years_ago']]
Out[65]:
               year years_ago
                           91
            0 1960
            1 1961
                           90
            2 1962
                           89
            3 1963
                           88
            4 1964
                           87
        19833 2046
                            5
        19834 2047
                            4
        19835 2048
                            3
        19836 2049
                            2
        19837 2050
                            1
       19838 rows × 2 columns
```

41. Przedstawić możliwości pracy z dużymi plikami przy użyciu argumentu chunksize